

Proyecto 1 - Probabilidad y estadística

Nicolas Vargas Flores 1001368855

Universidad de Antioquia 2024

```
datos = readtable("nutrition_elderly.csv");
```

Parte 1 - Procedimiento

a) ¿Cuál es la población bajo estudio?

```
generos = datos.gender == 1; % Esto da como resultado un logical array
```

```
hombres = 0;
```

```
mujeres = 0;
```

```
for i = 1:length(generos)
    if generos(i) == 1
        hombres = hombres + 1;
    else
        mujeres = mujeres + 1;
    end
end
```

```
hombres % Total de hombres
```

```
hombres = 85
```

```
mujeres % Total de mujeres
```

```
mujeres = 141
```

```
total_muestra = hombres + mujeres
```

```
total_muestra = 226
```

```
edades = datos.age; % Esto da como resultado un array con las edades
```

```
min_edad = min(edades)
```

```
min_edad = 65
```

```
max_edad = max(edades)
```

```
max_edad = 91
```

La población corresponde a personas adultas mayores entre los 65 y 91 años a los cuales se les hizo un seguimiento nutricional.

b) ¿La anterior información corresponde a una población o a una muestra?

La anterior información corresponde a una muestra. Específicamente es una muestra de 85 hombres y 141 mujeres para un total de 226 personas mayores involucradas en el estudio.

c) ¿Cuántas variables hay en el conjunto de datos?

```
variables_cantidad = length(datos.Properties.VariableNames)

variables_cantidad = 13
```

En este estudio se contemplaron 13 variables diferentes.

d) Realice una tabla con los tipos de características que tiene cada dataset.

```
variables = datos.Properties.VariableNames;
tipos = varfun(@class, datos, 'OutputFormat', 'cell');

tabla_tipos = table(variables', tipos', ...
                    'VariableNames', {'NombreVariable', 'Tipo'});
```

`varfun(@class, datos, 'OutputFormat', 'cell')` aplica la función `class` a cada variable en la tabla `datos` y devuelve los tipos de datos en una celda

Observe que la tabla de los tipos de característica de este dataset son todo datos tipo **double**, este tipo de datos hace referencia a los **double precision** que son números de alta precisión; números flotantes, también conocidos como **floats** o decimales

Lo anterior tiene coherencia pues las respuestas de todos los participantes del estudio se almacenaron como números que van del 0 al 5, cantidad (kg, numero de tazas, cm, años) u opciones binarias entre 1 y 2.

Parte 2 - Análisis descriptivo

1. Realizar las tablas de frecuencia de los datos a los que aplica y elija como presentar los gráficos más apropiados según el tipo de variable.
2. Resumir la información presente mediante tablas, gráficos adecuados y las medidas de ubicación, dispersión y simetría para aquellas variables que aplique. Recuerde usar gráficos de Histogramas, diagramas de cajas y bigotes, gráficos de dispersión.

Se pueden responder las dos preguntas anteriores con lo siguiente:

```
for i = 1:length(variables)
    if ismember(variables{i}, {'height', 'weight', 'age', 'tea', 'coffee'})
        % Para variables continuas, muestra estadísticas descriptivas,
        % un histograma y un diagrama de cajas y bigotes
        disp(['**Tabla de medidas de la variable ', ...
              variables{i}, '**'])
        disp(['Valor mínimo de ', variables{i}, ': ', ...
              num2str(min(datos.(variables{i})))]);
        disp(['Valor máximo de ', variables{i}, ': ', ...
              num2str(max(datos.(variables{i})))]);
        disp(['Media de ', variables{i}, ': ', ...
              num2str(mean(datos.(variables{i})))]);
        disp(['Mediana de ', variables{i}, ': ', ...
              num2str(median(datos.(variables{i})))]);
        disp(['Desviación estándar de ', variables{i}, ': ', ...
```

```


        num2str(std(datos.(variables{i}))))]);
disp(['Curtosis de ', variables{i}, ': ', ...
      num2str(kurtosis(datos.(variables{i}))))]);
disp(['Asimetría de ', variables{i}, ': ', ...
      num2str(skewness(datos.(variables{i}))))]);
figure; % Crea una nueva figura
histogram(datos.(variables{i}));
title(['Histograma de ', variables{i}]);
xlabel(variables{i});
ylabel('Frecuencia');
figure; % Crea una nueva figura
boxplot(datos.(variables{i}));
title(['Diagrama de cajas y bigotes de ', variables{i}]);
xlabel(variables{i});
ylabel('Valores');
else
    % Para variables categóricas, muestra una tabla de frecuencias
    % y un gráfico de barras
    tab = tabulate(datos.(variables{i}));
    disp(['**Tabla de frecuencias para la variable ', ...
          variables{i}, '**']);
    disp('Valores que toma la variable ');
    disp(tab(:,1));
    disp('Frecuencia ');
    disp(tab(:,2));
    disp('Frecuencia relativa (%) ');
    disp(tab(:,3));
    figure; % Crea una nueva figura
    bar(tab(:,2))
    title(['Gráfico de barras de ', variables{i}]);
    xlabel('Categorías');
    ylabel('Frecuencia');
    set(gca, 'XTickLabel',tab(:,1));
end
end

```

```

**Tabla de frecuencias para la variable gender:**
Valores que toma la variable
    1
    2
Frecuencia
    85
   141
Frecuencia relativa (%)
  37.6106
  62.3894

```



****Tabla de frecuencias para la variable situation:****

Valores que toma la variable

1

2

3

Frecuencia

98

119

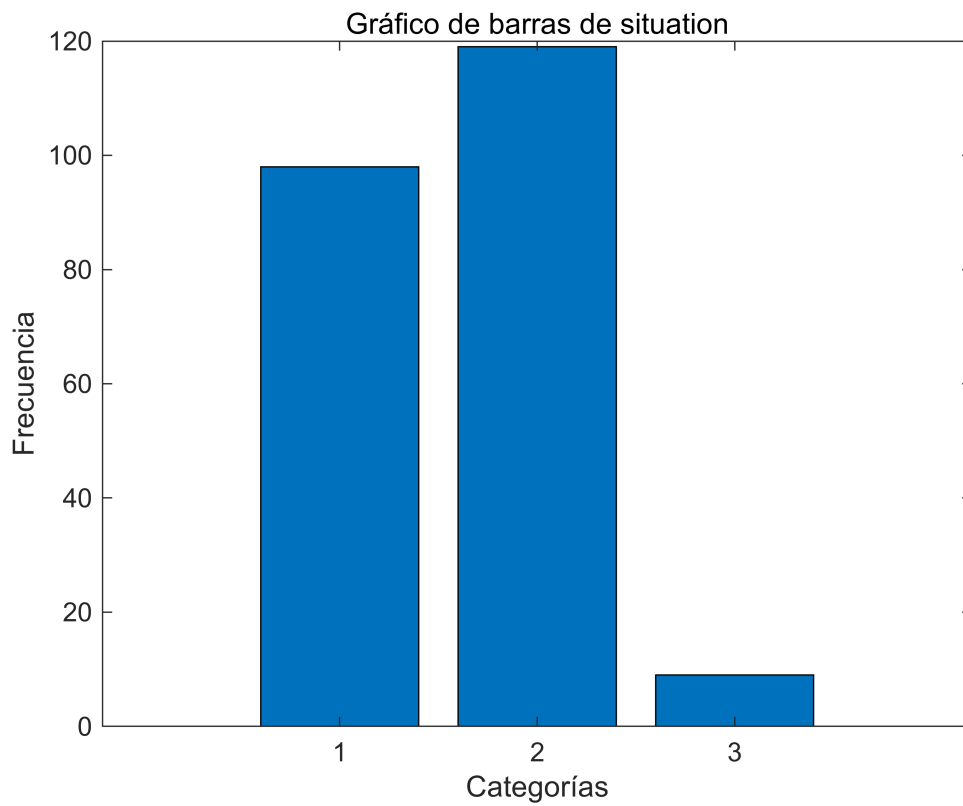
9

Frecuencia relativa (%)

43.3628

52.6549

3.9823



****Tabla de medidas de la variable tea:****

Valor mínimo de tea: 0

Valor máximo de tea: 10

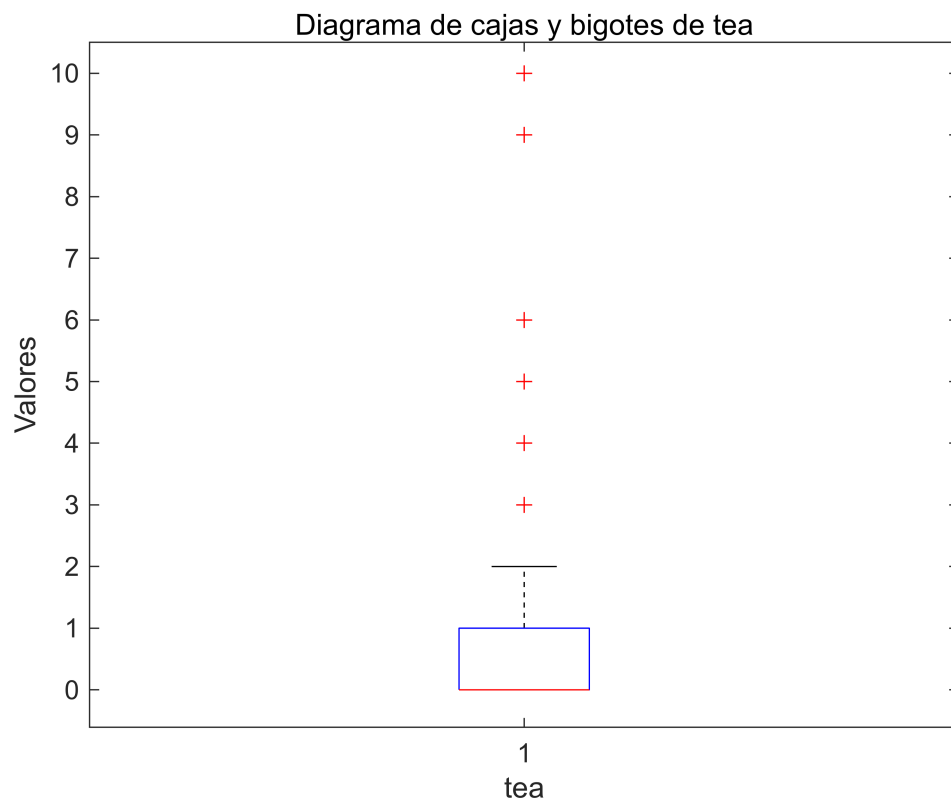

Media de tea: 0.71239

Mediana de tea: 0

Desviación estándar de tea: 1.4488

Curtosis de tea: 14.8628

Asimetría de tea: 2.9525



****Tabla de medidas de la variable coffee:****



Valor mínimo de coffee: 0

Valor máximo de coffee: 5

Media de coffee: 1.6195


Mediana de coffee: 2


Desviación estándar de coffee: 1.253
 Curtosis de coffee: 2.924
 Asimetría de coffee: 0.48847



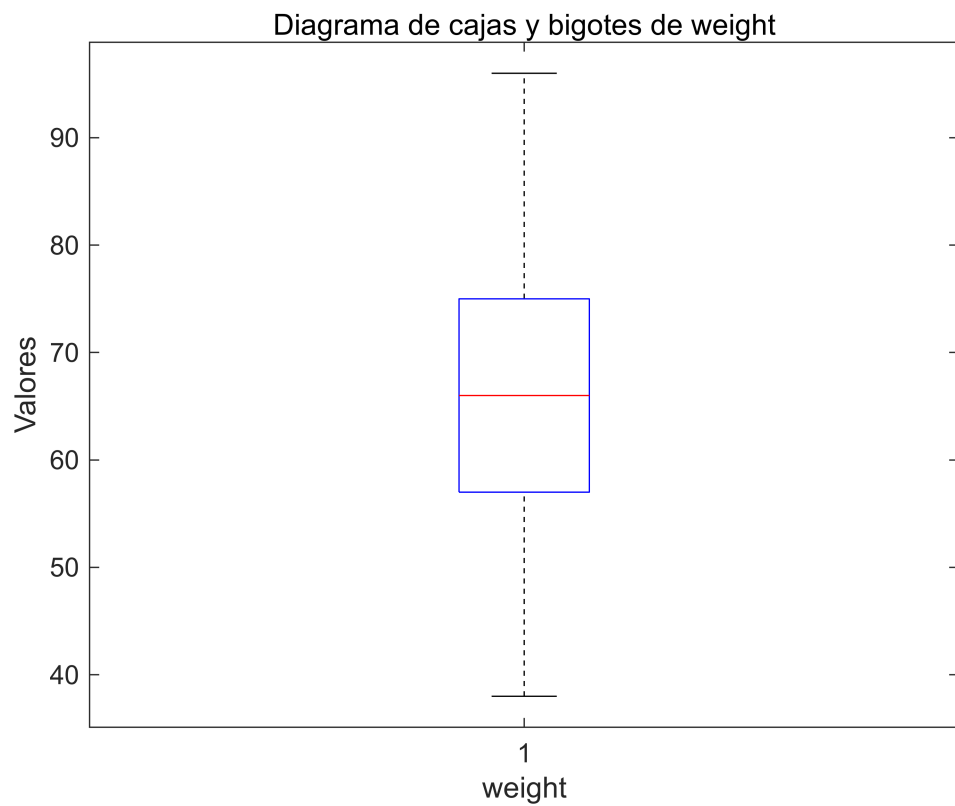

****Tabla de medidas de la variable height:****
 Valor mínimo de height: 140

Valor máximo de height: 188
Media de height: 163.9602
Mediana de height: 163
Desviación estándar de height: 9.0034
Curtosis de height: 2.7782
Asimetría de height: 0.42562





****Tabla de medidas de la variable weight:****
Valor mínimo de weight: 38
Valor máximo de weight: 96
Media de weight: 66.4823
Mediana de weight: 66
Desviación estándar de weight: 12.0334
Curtosis de weight: 2.5062
Asimetría de weight: 0.14639



****Tabla de medidas de la variable age:****

Valor mínimo de age: 65

Valor máximo de age: 91

Media de age: 74.4779

Mediana de age: 74

Desviación estándar de age: 6.0053
 Curtosis de age: 3.0017
 Asimetría de age: 0.66909

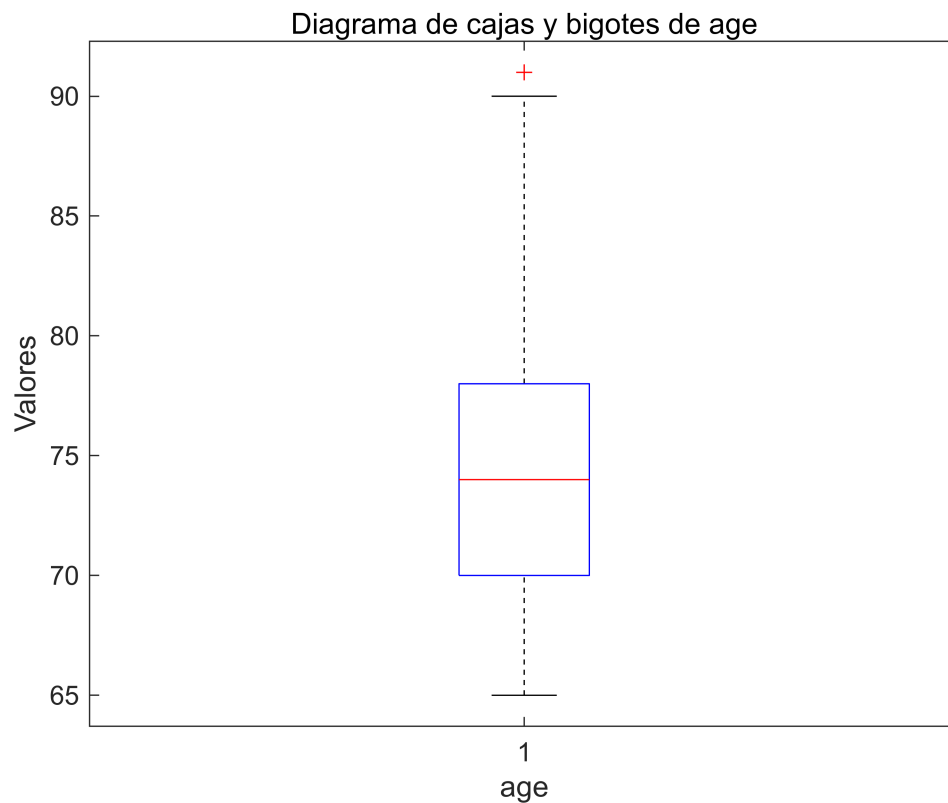




Tabla de frecuencias para la variable meat:
 Valores que toma la variable

```

0
1
2
3
4
5
Frecuencia
1
3
11
83
67
61
Frecuencia relativa (%)
0.4425
1.3274
4.8673
36.7257
29.6460
26.9912

```




****Tabla de frecuencias para la variable fish:****
Valores que toma la variable

```

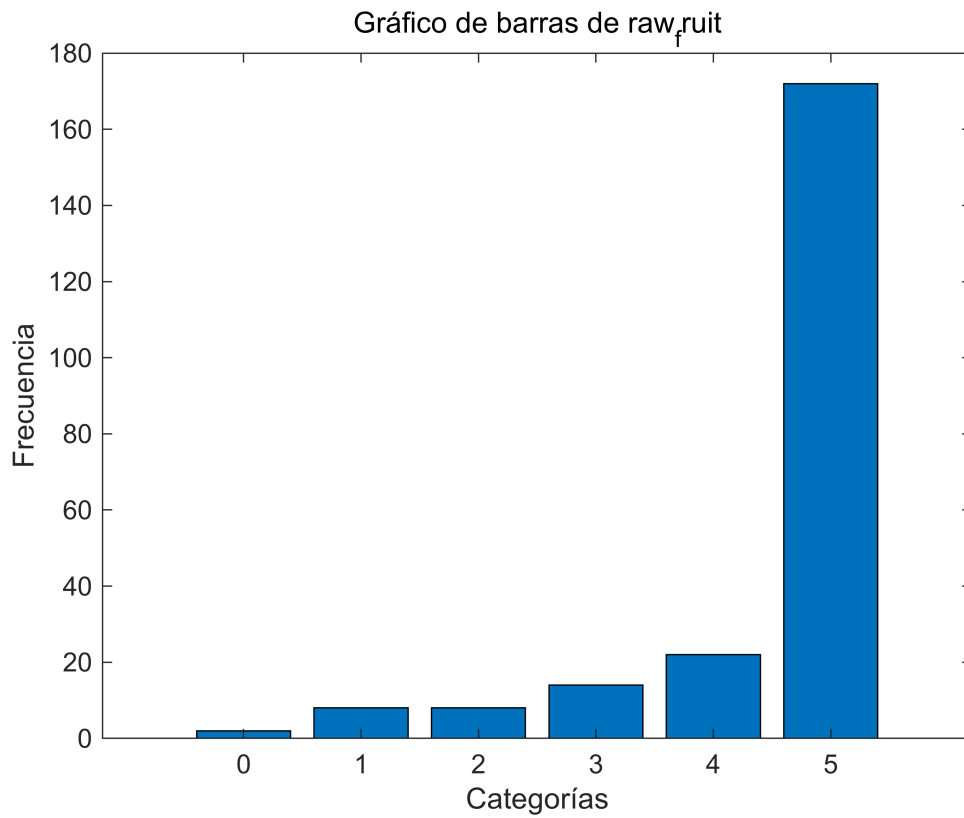
0
1
2
3
4
5
Frecuencia
4
21
61
118

```

15
7
Frecuencia relativa (%)
1.7699
9.2920
26.9912
52.2124
6.6372
3.0973



****Tabla de frecuencias para la variable raw_fruit:****
Valores que toma la variable
0
1
2
3
4
5
Frecuencia
2
8
8
14
22
172
Frecuencia relativa (%)
0.8850
3.5398
3.5398
6.1947
9.7345
76.1062



****Tabla de frecuencias para la variable cooked_fruit_veg:****

Valores que toma la variable

0

1

2

3

4

5

Frecuencia

2

3

7

30

36

148

Frecuencia relativa (%)

0.8850

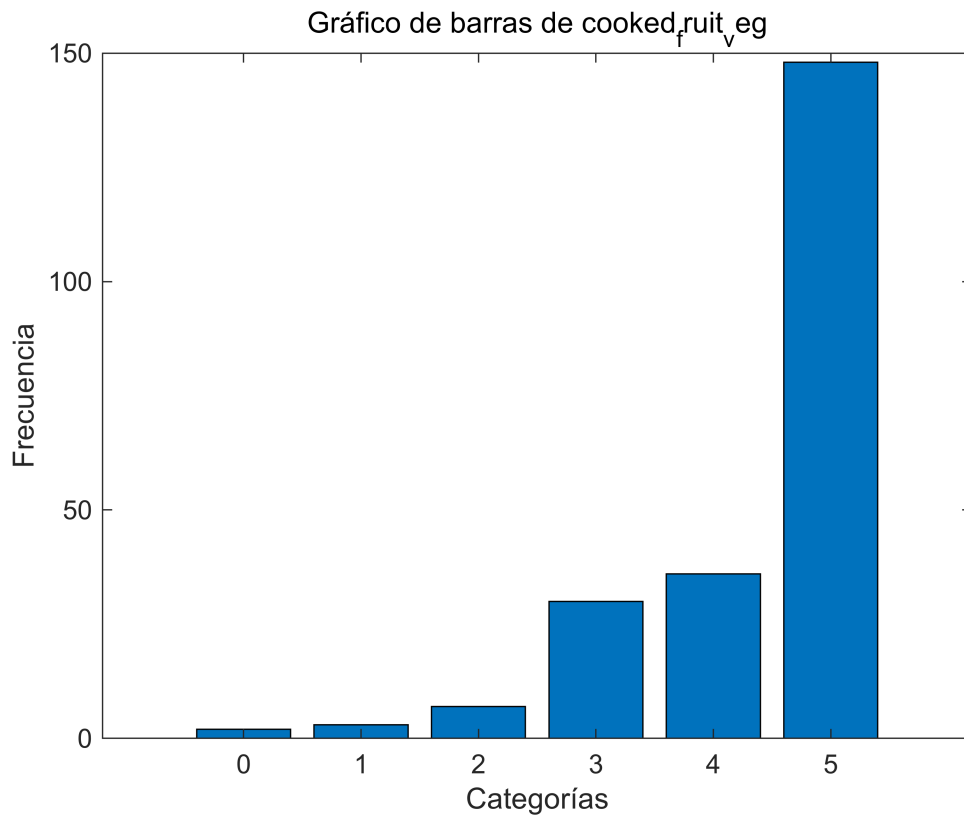
1.3274

3.0973

13.2743

15.9292

65.4867



****Tabla de frecuencias para la variable chocol:****

Valores que toma la variable

0

1

2

3

4

5

Frecuencia

50

62

16

22

11

65

Frecuencia relativa (%)

22.1239

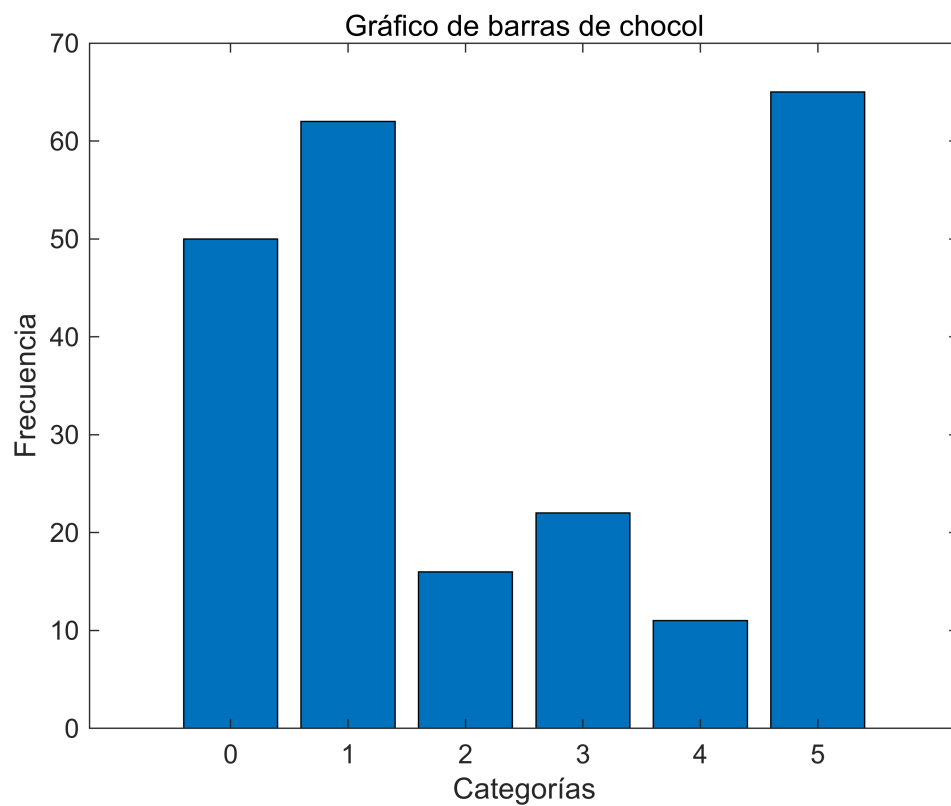
27.4336

7.0796

9.7345

4.8673

28.7611



****Tabla de frecuencias para la variable fat:****

Valores que toma la variable

1

2

3

4

5

6

7

8

Frecuencia

15

27

48

68

40

23

1

4

Frecuencia relativa (%)

6.6372

11.9469

21.2389


30.0885

17.6991

10.1770

0.4425

1.7699



En el código, se utilizan dos tipos de gráficos: **histogramas y gráficos de barras**. La elección entre estos dos depende del tipo de variable que se está analizando.

- **Histograma:** Se utiliza para variables continuas, como *'height'*, *'weight'*, *'age'*, *'tea'*, *'coffee'*. Las variables continuas pueden tomar cualquier valor dentro de un rango específico. Los histogramas son útiles para visualizar la distribución de los datos y pueden ayudar a identificar tendencias, valores atípicos y la forma de la distribución (por ejemplo, si es simétrica, sesgada a la derecha o a la izquierda).
- **Gráfico de barras:** Se utiliza para variables categóricas, que son aquellas que tienen un número limitado y fijo de categorías posibles. En este caso, todas las variables que no son *'height'*, *'weight'*, *'age'*, *'tea'*, *'coffee'* se consideran categóricas. Los gráficos de barras son útiles para comparar la frecuencia o proporción de cada categoría en la variable.

Las variables continuas pueden tomar cualquier valor dentro de un rango específico y, por lo tanto, tienen una distribución de datos que puede ser descrita por medidas de ubicación central (como la media o la mediana), medidas de dispersión (como la desviación estándar), y medidas de forma (como la curtosis y la asimetría).

- **Desviación estándar:** Mide cuánto se dispersan los datos alrededor de la media. Una desviación estándar alta indica que los datos están muy dispersos, mientras que una desviación estándar baja indica que los datos están muy concentrados alrededor de la media.
- **Curtosis:** Mide el “pico” o la “cola pesada” de la distribución. Una curtosis alta indica una distribución con colas pesadas y un pico agudo, mientras que una curtosis baja indica una distribución con colas ligeras y un pico menos pronunciado.

- **Asimetría:** Mide la simetría de la distribución. Una asimetría positiva indica una distribución con una cola derecha más larga, mientras que una asimetría negativa indica una distribución con una cola izquierda más larga.

El **diagrama de cajas y bigotes** es otra herramienta útil para visualizar la distribución de una variable continua. Muestra la mediana, los cuartiles y los valores atípicos, proporcionando una visión rápida de la distribución de los datos.

Por otro lado, las variables categóricas tienen un número limitado y fijo de categorías posibles. No tiene sentido calcular la desviación estándar, la curtosis o la asimetría para estas variables, ya que no tienen una distribución de datos en el sentido tradicional. En su lugar, se utilizan tablas de frecuencias y gráficos de barras para describir la distribución de una variable categórica. Estos muestran la frecuencia de cada categoría, lo que permite ver rápidamente qué categorías son las más comunes.

3. Observar a detalle las estadísticas e identificar si existen diferencias altas entre cada percentil y en los percentiles extremos con valores máximos y mínimos de cada característica/variable.

Para responder lo anterior se calcularán los percentiles de los datos y se compararán con los valores mínimos y máximos.

```
for i = 1:length(variables)
    if ismember(variables{i}, {'height', 'weight', 'age', 'tea', 'coffee'})
        % Para variables continuas, calcula los percentiles
        % y compara con los valores mínimos y máximos
        disp(['**Análisis de percentiles para la variable ', ...
            variables{i}, '**'])
        percentiles = prctile(datos.(variables{i}), [0 25 50 75 100]);
        disp(['Percentil 0 (mínimo) de ', variables{i}, ': ', ...
            num2str(percentiles(1))]);
        disp(['Percentil 25 de ', variables{i}, ': ', ...
            num2str(percentiles(2))]);
        disp(['Percentil 50 (mediana) de ', variables{i}, ': ', ...
            num2str(percentiles(3))]);
        disp(['Percentil 75 de ', variables{i}, ': ', ...
            num2str(percentiles(4))]);
        disp(['Percentil 100 (máximo) de ', variables{i}, ': ', ...
            num2str(percentiles(5))]);
        disp(['Diferencia entre percentil 25 y mínimo de ', ...
            variables{i}, ': ', num2str(percentiles(2)-percentiles(1))]);
        disp(['Diferencia entre percentil 75 y máximo de ', ...
            variables{i}, ': ', num2str(percentiles(5)-percentiles(4))]);
        disp('')
    end
end
```

```
**Análisis de percentiles para la variable tea**
Percentil 0 (mínimo) de tea: 0
Percentil 25 de tea: 0
Percentil 50 (mediana) de tea: 0
Percentil 75 de tea: 1
```

Percentil 100 (máximo) de tea: 10
Diferencia entre percentil 25 y mínimo de tea: 0
Diferencia entre percentil 75 y máximo de tea: 9

****Análisis de percentiles para la variable coffee****
Percentil 0 (mínimo) de coffee: 0
Percentil 25 de coffee: 1
Percentil 50 (mediana) de coffee: 2
Percentil 75 de coffee: 2
Percentil 100 (máximo) de coffee: 5
Diferencia entre percentil 25 y mínimo de coffee: 1
Diferencia entre percentil 75 y máximo de coffee: 3

****Análisis de percentiles para la variable height****
Percentil 0 (mínimo) de height: 140
Percentil 25 de height: 157
Percentil 50 (mediana) de height: 163
Percentil 75 de height: 170
Percentil 100 (máximo) de height: 188
Diferencia entre percentil 25 y mínimo de height: 17
Diferencia entre percentil 75 y máximo de height: 18

****Análisis de percentiles para la variable weight****
Percentil 0 (mínimo) de weight: 38
Percentil 25 de weight: 57
Percentil 50 (mediana) de weight: 66
Percentil 75 de weight: 75
Percentil 100 (máximo) de weight: 96
Diferencia entre percentil 25 y mínimo de weight: 19
Diferencia entre percentil 75 y máximo de weight: 21

****Análisis de percentiles para la variable age****
Percentil 0 (mínimo) de age: 65
Percentil 25 de age: 70
Percentil 50 (mediana) de age: 74
Percentil 75 de age: 78
Percentil 100 (máximo) de age: 91
Diferencia entre percentil 25 y mínimo de age: 5
Diferencia entre percentil 75 y máximo de age: 13

La diferencia entre el percentil 25 y el mínimo, y entre el percentil 75 y el máximo ayudan a identificar si existen diferencias altas entre cada percentil y en los percentiles extremos con los valores máximos y mínimos. Si estas diferencias son grandes, podría indicar la presencia de valores atípicos en los datos.

A partir del análisis de percentiles, se concluye:

- **Té (tea):** La mayoría de las personas mayores no consumen té a diario (mediana y percentil 25 son 0). Sin embargo, hay una diferencia significativa entre el percentil 75 y el valor máximo (9 tazas), lo que indica que hay algunas personas que consumen una cantidad considerable de té al día.
- **Café (coffee):** A diferencia del té, la mayoría de las personas mayores consumen al menos una taza de café al día (percentil 25 es 1 y mediana es 2). La diferencia entre el percentil 75 y el valor máximo es de 3 tazas, lo que indica una menor variabilidad en el consumo de café en comparación con el té.
- **Altura (height):** La altura de las personas mayores varía entre 140 cm y 188 cm, con una mediana de 163 cm. La diferencia entre el percentil 25 y el mínimo, así como entre el percentil 75 y el máximo, es relativamente pequeña (17 cm y 18 cm respectivamente), lo que indica que la mayoría de las personas mayores tienen una altura dentro de este rango.

- **Peso (*weight*):** El peso de las personas mayores varía entre 38 kg y 96 kg, con una mediana de 66 kg. La diferencia entre el percentil 25 y el mínimo, así como entre el percentil 75 y el máximo, es relativamente pequeña (19 kg y 21 kg respectivamente), lo que indica que la mayoría de las personas mayores tienen un peso dentro de este rango. En otras palabras, el 50% central de los datos que se encuentra entre el percentil 25 y el percentil 75 están concentrados alrededor de la mediana (66 kg), con una variabilidad de alrededor de 18 kg (75 kg - 57 kg).
- **Edad (*age*):** La edad de las personas mayores varía entre 65 años y 91 años, con una mediana de 74 años. La diferencia entre el percentil 25 y el mínimo es de 5 años, mientras que la diferencia entre el percentil 75 y el máximo es de 13 años. Esto indica que hay una mayor variabilidad en la edad de las personas mayores en el extremo superior del rango de edades.

4. Identificar si existen valores atípicos en las variables, ¿estos valores podrían generar un falso análisis?

Para identificar los valores atípicos se utilizará el método del rango intercuartil (IQR). Este método considera como valores atípicos aquellos que están por debajo del primer cuartil menos 1.5 veces el IQR o por encima del tercer cuartil más 1.5 veces el IQR.

```
for i = 1:length(variables)
    if ismember(variables{i}, {'height', 'weight', 'age', 'tea', 'coffee'})
        % Para variables continuas, calcula los percentiles
        % e identifica los valores atípicos
        disp(' ');
        disp('=====');
        disp(' ');
        disp(['**Análisis de valores atípicos para la variable ', ...
            variables{i}, '**'])
        Q1 = prctile(datos.(variables{i}), 25);
        Q3 = prctile(datos.(variables{i}), 75);
        IQR = Q3 - Q1;
        lower_bound = Q1 - 1.5 * IQR;
        upper_bound = Q3 + 1.5 * IQR;
        outliers = datos.(variables{i}) < lower_bound | ...
            datos.(variables{i}) > upper_bound;
        disp(['Número de valores atípicos en ', variables{i}, ...
            ': ', num2str(sum(outliers))]);
    end
end
```

```
=====

**Análisis de valores atípicos para la variable tea**
Número de valores atípicos en tea: 21

=====

**Análisis de valores atípicos para la variable coffee**
Número de valores atípicos en coffee: 13
```

```
=====
```

```
**Análisis de valores atípicos para la variable height**  
Número de valores atípicos en height: 0
```

```
=====
```

```
**Análisis de valores atípicos para la variable weight**  
Número de valores atípicos en weight: 0
```

```
=====
```

```
**Análisis de valores atípicos para la variable age**  
Número de valores atípicos en age: 2
```

Los valores atípicos pueden tener un impacto significativo en las estadísticas descriptivas, como la media y la desviación estándar, y pueden sesgar los resultados.

Por ejemplo, un valor atípico muy alto puede aumentar la media, dando la impresión de que todos los valores son más altos de lo que realmente son. Del mismo modo, los valores atípicos pueden aumentar la desviación estándar, dando la impresión de que los datos son más dispersos de lo que realmente son.

Por lo tanto, es importante identificar y tratar adecuadamente los valores atípicos antes de realizar un análisis de los datos. Esto podría implicar eliminar los valores atípicos, transformar los datos, o utilizar otros tipos de métodos estadísticos más complejos que tengan en cuenta la naturaleza de dichos valores atípicos

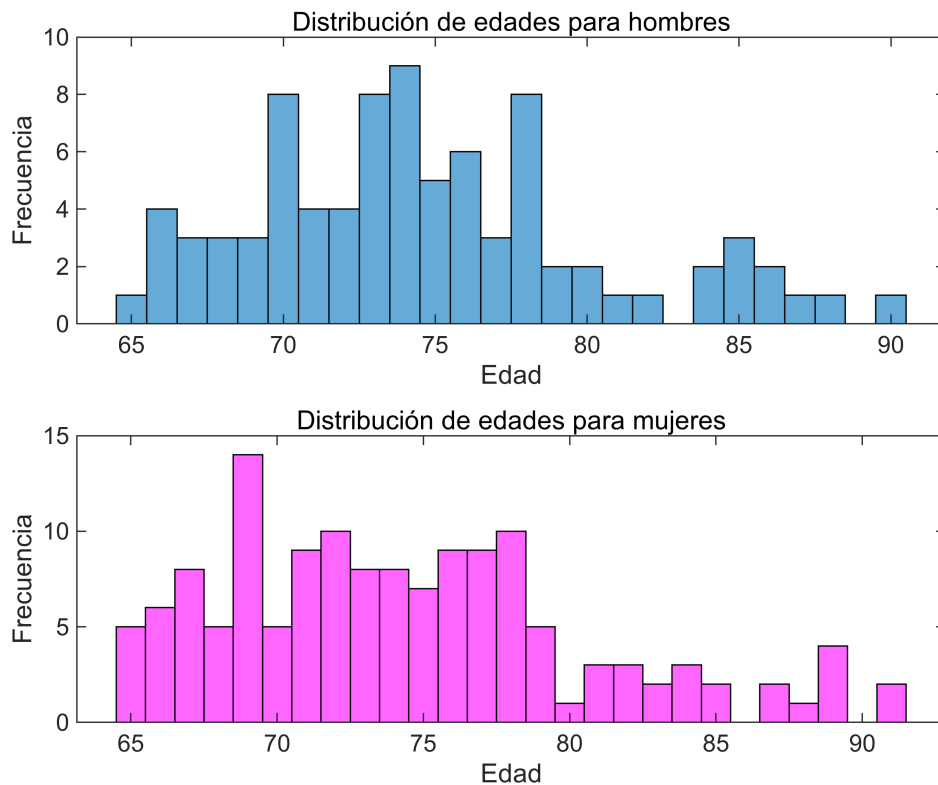
Parte 3 - Análisis entre variables

- 1. Elegir qué variables (mínimo 2) permiten agrupar todos los datos para realizar análisis comparativo por grupos, luego analice las variables según su elección. Elabore gráficos adecuados para presentar la información.**

Para este análisis, la opción clásica es elegir las variables '*gender*' y '*age*' para agrupar los datos. '*gender*' es una variable categórica que divide naturalmente los datos en dos grupos, y '*age*' es una variable continua que puede proporcionar información interesante cuando se analiza por grupos de género.

```
grupo_hombres = datos(datos.gender == 1, :);  
grupo_mujeres = datos(datos.gender == 2, :);  
edad_hombres = grupo_hombres.age;  
edad_mujeres = grupo_mujeres.age;  
  
% Crear histogramas para la variable 'age' en cada grupo  
figure;  
subplot(2,1,1);  
histogram(edad_hombres);  
title('Distribución de edades para hombres');  
xlabel('Edad');  
ylabel('Frecuencia');  
  
subplot(2,1,2);  
histogram(edad_mujeres, 'FaceColor', 'm');  
title('Distribución de edades para mujeres');  
xlabel('Edad');
```

```
ylabel('Frecuencia');
```




Otro punto de vista:

Se hace un análisis de correlación entre *'height'* y *'weight'*. Un gráfico de dispersión es una buena opción para visualizar la relación entre estas dos variables.

Cada punto en el gráfico representa una observación en el conjunto de datos. La posición de cada punto en el eje x e y corresponde a su valor de *'height'* y *'weight'*, respectivamente.

```
% Extraer las variables de interés
altura = datos.height;
peso = datos.weight;

% Crear un gráfico de dispersión
figure;
scatter(altura, peso, 15, peso, 'filled');
colormap(jet); % Crea un degradado de colores tipo arcoiris (estético)
title('Relación entre altura y peso');
xlabel('Altura (cm)');
ylabel('Peso (kg)');
```



El gráfico de dispersión muestra una tendencia donde los puntos se agrupan a lo largo de una línea recta con pendiente positiva, pero no es muy pronunciada. Se puede concluir que existe una correlación positiva entre las dos variables. En este caso, indica que a medida que la altura aumenta, el peso también tiende a aumentar.


Aunque la correlación es positiva, no es perfectamente fuerte (la agrupación de puntos no sigue una línea recta perfecta), lo que indica que hay una cantidad significativa de variabilidad en los datos. Esto significa que, aunque en general las personas más altas tienden a pesar más, hay muchas excepciones a esta tendencia.

2. Realizar la matriz de correlación y el análisis de varianza entre todas las variables

```
matriz_correlacion = corrcoef(table2array(datos));

% Visualizar la matriz de correlación
figure;
imagesc(matriz_correlacion);
colorbar; % Agrega una barra de colores para indicar los valores de correlación
title('Matriz de correlación');
xlabel('Variables');
ylabel('Variables');

% Etiquetas de los ejes x e y
xticks(1:length(datos.Properties.VariableNames));
xticklabels(datos.Properties.VariableNames);
xtickangle(90); % Rotar las etiquetas 90 grados
yticks(1:length(datos.Properties.VariableNames));
yticklabels(datos.Properties.VariableNames);
```




En el bloque anterior, `imagesc(matriz_correlacion)` crea una representación visual de la matriz de correlación. Los colores de los elementos de la matriz indican los valores de correlación, con una barra de colores a la derecha que indica qué colores corresponden a qué valores de correlación.

```
% Realizar el análisis de varianza (ANOVA) para cada variable
for i = 1:width(datos)
    disp('=====');
    disp(['Análisis de varianza ANOVA para ', ...
        datos.Properties.VariableNames{i}, ':']);
    [p, tbl, stats] = anova1([table2array(grupo_hombres(:,i)); ...
        table2array(grupo_mujeres(:,i))], ...
        [ones(size(grupo_hombres, 1), 1); 2*ones(size(grupo_mujeres, 1), 1)]);
    disp(tbl);
    disp('=====');
end
```

```
=====
Análisis de varianza ANOVA para gender:
```



ANOVA Table					
Source	SS	df	MS	F	Prob>F
Groups	53.031	1	53.031	-8.35906e+17	1
Error	-0	224	-0		
Total	53.031	225			



{'Source'}	{'SS' }	{'df' }	{'MS' }	{'F' }	{'Prob>F' }
{'Groups'}	{[53.0310]}	{[1]}	{[53.0310]}	{[-8.3591e+17]}	{[1]}
{'Error' }	{[-1.4211e-14]}	{[224]}	{[-6.3441e-17]}	{0x0 double }	{0x0 double }
{'Total' }	{[53.0310]}	{[225]}	{0x0 double }	{0x0 double }	{0x0 double }

=====
 =====
 Análisis de varianza ANOVA para situation:


ANOVA Table					
Source	SS	df	MS	F	Prob>F
Groups	4.5149	1	4.51487	15	0.0001
Error	67.4365	224	0.30106		
Total	71.9513	225			



```
{'Source'}      {'SS'      }      {'df'  }      {'MS'      }      {'F'      }      {'Prob>F'      }
{'Groups'}      {[ 4.5149]}      {[ 1]}      {[ 4.5149]}      {[ 14.9968]}      {[1.4136e-04]}
{'Error' }      {[67.4365]}      {[224]}      {[ 0.3011]}      {0x0 double}      {0x0 double }
{'Total' }      {[71.9513]}      {[225]}      {0x0 double}      {0x0 double}      {0x0 double }
```

```
=====
=====
Análisis de varianza ANOVA para tea:
```

ANOVA Table					
Source	SS	df	MS	F	Prob>F
Groups	11.368	1	11.368	5.52	0.0196
Error	460.937	224	2.0578		
Total	472.305	225			




```
{'Source'}      {'SS'      }      {'df'  }      {'MS'      }      {'F'      }      {'Prob>F'  }
{'Groups'}      {[ 11.3680]}      {[ 1]}      {[ 11.3680]}      {[ 5.5245]}      {[ 0.0196]}
{'Error' }      {[460.9373]}      {[224]}      {[ 2.0578]}      {[0x0 double]}      {[0x0 double]}
{'Total' }      {[472.3053]}      {[225]}      {[0x0 double]}      {[0x0 double]}      {[0x0 double]}
```

=====

=====

Análisis de varianza ANOVA para coffee:


ANOVA Table					
Source	SS	df	MS	F	Prob>F
Groups	8.591	1	8.59148	5.58	0.019
Error	344.683	224	1.53876		
Total	353.274	225			



```
{'Source'}      {'SS'      }      {'df'  }      {'MS'      }      {'F'      }      {'Prob>F'  }
{'Groups'}      {[ 8.5915]}      {[ 1]}      {[ 8.5915]}      {[ 5.5834]}      {[ 0.0190]}
{'Error' }      {[344.6829]}      {[224]}      {[ 1.5388]}      {[0x0 double]}      {[0x0 double]}
{'Total' }      {[353.2743]}      {[225]}      {[0x0 double]}      {[0x0 double]}      {[0x0 double]}
```

```
=====
=====
Análisis de varianza ANOVA para height:
```

ANOVA Table					
Source	SS	df	MS	F	Prob>F
Groups	9977	1	9976.98	270.51	2.16846e-40
Error	8261.7	224	36.88		
Total	18238.6	225			




```
{'Source'}      {'SS'      }      {'df'  }      {'MS'      }      {'F'      }      {'Prob>F'   }
{'Groups'}      {[9.9770e+03]}      {[ 1]}      {[9.9770e+03]}      {[270.5077]}      {[2.1685e-40]}
{'Error' }      {[8.2617e+03]}      {[224]}      {[ 36.8824]}      {[0x0 double]}      {[0x0 double ]}
{'Total' }      {[1.8239e+04]}      {[225]}      {[0x0 double ]}      {[0x0 double ]}      {[0x0 double ]}
```

=====

=====

Análisis de varianza ANOVA para weight:


ANOVA Table					
Source	SS	df	MS	F	Prob>F
Groups	10834.6	1	10834.6	111.61	1.97933e-21
Error	21745.8	224	97.1		
Total	32580.4	225			



```
{'Source'}      {'SS'      }      {'df'  }      {'MS'      }      {'F'      }      {'Prob>F'  }
{'Groups'}      {[1.0835e+04]}      {[ 1]}      {[1.0835e+04]}      {[111.6057]}      {[1.9793e-21]}
{'Error' }      {[2.1746e+04]}      {[224]}      {[ 97.0795]}      {[0x0 double]}      {[0x0 double ]}
{'Total' }      {[3.2580e+04]}      {[225]}      {[0x0 double ]}      {[0x0 double ]}      {[0x0 double ]}
```

```
=====
=====
Análisis de varianza ANOVA para age:
```


ANOVA Table					
Source	SS	df	MS	F	Prob>F
Groups	7.08	1	7.0827	0.2	0.6586
Error	8107.31	224	36.1933		
Total	8114.39	225			



```
{'Source'}      {'SS'      }      {'df'  }      {'MS'      }      {'F'      }      {'Prob>F' }
{'Groups'}      {[ 7.0827]}      {[ 1]}      {[ 7.0827]}      {[ 0.1957]}      {[ 0.6586]}
{'Error' }      {[8.1073e+03]}      {[224]}      {[ 36.1933]}      {[0x0 double]}      {[0x0 double]}
{'Total' }      {[8.1144e+03]}      {[225]}      {[0x0 double]}      {[0x0 double]}      {[0x0 double]}
```

```
=====
=====
Análisis de varianza ANOVA para meat:
```

ANOVA Table					
Source	SS	df	MS	F	Prob>F
Groups	1.043	1	1.04325	1.08	0.2989
Error	215.581	224	0.96241		
Total	216.624	225			




```
{'Source'}      {'SS'      }      {'df' }      {'MS'      }      {'F'      }      {'Prob>F' }
{'Groups'}      {[ 1.0433]}      {[ 1]}      {[ 1.0433]}      {[ 1.0840]}      {[ 0.2989]}
{'Error' }      {[215.5806]}      {[224]}      {[ 0.9624]}      {[0x0 double]}      {[0x0 double]}
{'Total' }      {[216.6239]}      {[225]}      {[0x0 double]}      {[0x0 double]}      {[0x0 double]}
```

=====

=====

Análisis de varianza ANOVA para fish:

ANOVA Table					
Source	SS	df	MS	F	Prob>F
Groups	0.211	1	0.21101	0.25	0.6194
Error	191.063	224	0.85296		
Total	191.274	225			




```
{'Source'}      {'SS'      }      {'df'  }      {'MS'      }      {'F'      }      {'Prob>F'  }
{'Groups'}      {[ 0.2110]}      {[ 1]}      {[ 0.2110]}      {[ 0.2474]}      {[ 0.6194]}
{'Error' }      {[191.0633]}      {[224]}      {[ 0.8530]}      {[0x0 double]}      {[0x0 double]}
{'Total' }      {[191.2743]}      {[225]}      {[0x0 double]}      {[0x0 double]}      {[0x0 double]}
```

```
=====
=====
```

Análisis de varianza ANOVA para raw_fruit:

ANOVA Table					
Source	SS	df	MS	F	Prob>F
Groups	3.502	1	3.50231	2.96	0.0867
Error	264.958	224	1.18285		
Total	268.46	225			




```
{'Source'}      {'SS'      }      {'df'  }      {'MS'      }      {'F'      }      {'Prob>F'  }
{'Groups'}      {[ 3.5023]}      {[ 1]}      {[ 3.5023]}      {[ 2.9609]}      {[ 0.0867]}
{'Error' }      {[264.9579]}      {[224]}      {[ 1.1828]}      {[0x0 double]}      {[0x0 double]}
{'Total' }      {[268.4602]}      {[225]}      {[0x0 double]}      {[0x0 double]}      {[0x0 double]}
```

```
=====
=====
```

Análisis de varianza ANOVA para cooked_fruit_veg:


ANOVA Table					
Source	SS	df	MS	F	Prob>F
Groups	0.42	1	0.42032	0.41	0.5239
Error	231.089	224	1.03165		
Total	231.509	225			



```
{'Source'}      {'SS'      }      {'df'  }      {'MS'      }      {'F'      }      {'Prob>F'  }
{'Groups'}      {[ 0.4203]}      {[ 1]}      {[ 0.4203]}      {[ 0.4074]}      {[ 0.5239]}
{'Error' }      {[231.0885]}      {[224]}      {[ 1.0316]}      {[0x0 double]}      {[0x0 double]}
{'Total' }      {[231.5088]}      {[225]}      {[0x0 double]}      {[0x0 double]}      {[0x0 double]}
```

```
=====
=====
Análisis de varianza ANOVA para chocol:
```


ANOVA Table					
Source	SS	df	MS	F	Prob>F
Groups	1.514	1	1.51392	0.38	0.5366
Error	885.252	224	3.95202		
Total	886.765	225			



```
{'Source'}      {'SS'      }      {'df'  }      {'MS'      }      {'F'      }      {'Prob>F'  }
{'Groups'}      {[ 1.5139]}      {[ 1]}      {[ 1.5139]}      {[ 0.3831]}      {[ 0.5366]}
{'Error' }      {[885.2516]}      {[224]}      {[ 3.9520]}      {[0x0 double]}      {[0x0 double]}
{'Total' }      {[886.7655]}      {[225]}      {[0x0 double]}      {[0x0 double]}      {[0x0 double]}
```

```
=====
=====
Análisis de varianza ANOVA para fat:
```

ANOVA Table					
Source	SS	df	MS	F	Prob>F
Groups	1.269	1	1.26903	0.58	0.4456
Error	486.926	224	2.17378		
Total	488.195	225			



```

{'Source' }      {'SS'      }      {'df'  }      {'MS'      }      {'F'       }      {'Prob>F'  }
{'Groups' }      {[ 1.2690]}      {[ 1  ]}      {[ 1.2690]}      {[ 0.5838]}      {[ 0.4456]}
{'Error'  }      {[486.9257]}      {[224]}      {[ 2.1738]}      {[0x0 double]}      {[0x0 double]}
{'Total'  }      {[488.1947]}      {[225]}      {[0x0 double]}      {[0x0 double]}      {[0x0 double]}
=====

```

El Análisis de Varianza (ANOVA) es un método estadístico que se utiliza para determinar si existen diferencias significativas entre las medias de dos o más poblaciones. En el contexto del proyecto, se utiliza para analizar si la media de una variable difiere significativamente entre hombres y mujeres. Si el resultado del ANOVA es significativo, esto indica que al menos una de las medias de los grupos es diferente de las demás.

Parte 4 - Análisis final y conclusiones

1. **Establecer conclusiones por cada uno de los análisis realizados en los parámetros anteriores y por cada variable analizada. Es útil plantearse preguntas estadísticas para concluir sobre el conjunto de datos, un ejemplo de esas preguntas se presenta a continuación:**

Basado en los resultados del análisis de varianza (ANOVA), se pueden sacar varias conclusiones interesantes sobre las diferencias entre hombres y mujeres en la muestra de adultos mayores:

1. **Situación social:** Los hombres tienden a vivir con su cónyuge, mientras que las mujeres tienen una situación social más variada, con una concentración en ser solteras.
2. **Consumo de té y café:** Ambos géneros tienden a no tomar té, pero los hombres beben en promedio más tazas de café que las mujeres.
3. **Altura y peso:** En promedio, los hombres de la muestra son más altos y pesan más que las mujeres.
4. **Edad:** La edad de ambos grupos es extremadamente similar.

5. **Dieta:** Los hombres tienden a comer carne más frecuentemente que las mujeres, mientras que el consumo de pescado es igual en ambos grupos. Los hombres tienden a comer más frutas crudas semanalmente que las mujeres, pero el consumo de frutas y verduras cocidas es prácticamente igual en ambos grupos.
6. **Consumo de chocolate:** Las mujeres consumen, en promedio, más chocolate que los hombres.
7. **Uso de aceite de girasol:** El uso de aceite de girasol es promedio en ambos grupos.

2. Si el análisis de datos se fuese a hacer público, ¿cuál sería el titular de la noticia que pondrían para llamar la atención de los resultados?

Estudio revela: Los hombres mayores prefieren el café y la compañía, las mujeres mayores eligen el chocolate y la soltería