

Proyecto 1 - Probabilidad y estadística

Nicolas Vargas Flores 1001368855

Universidad de Antioquia 2024

```
datos = readtable("nutrition_elderly.csv");
```

Parte 1 - Procedimiento

a) ¿Cuál es la población bajo estudio?

```
generos = datos.gender == 1; % Esto da como resultado un logical array

hombres = 0;
mujeres = 0;

for i = 1:length(generos)
    if generos(i) == 1
        hombres = hombres + 1;
    else
        mujeres = mujeres + 1;
    end
end

hombres % Total de hombres
```

```
hombres = 85
```

```
mujeres % Total de mujeres
```

```
mujeres = 141
```

```
total_muestra = hombres + mujeres
```

```
total_muestra = 226
```

```
edades = datos.age; % Esto da como resultado un array con las edades
min_edad = min(edades)
```

```
min_edad = 65
```

```
max_edad = max(edades)
```

```
max_edad = 91
```

La población corresponde a personas adultas mayores entre los 65 y 91 años a los cuales se les hizo un seguimiento nutricional.

b) ¿La anterior información corresponde a una población o a una muestra?

La anterior información corresponde a una muestra. Específicamente es una muestra de 85 hombres y 141 mujeres para un total de 226 personas mayores involucradas en el estudio.

c) ¿Cuántas variables hay en el conjunto de datos?

```
variables_cantidad = length(datos.Properties.VariableNames)
```

```
variables_cantidad = 13
```

En este estudio se contemplaron 13 variables diferentes.

d) Realice una tabla con los tipos de características que tiene cada dataset.

```
variables = datos.Properties.VariableNames;  
tipos = varfun(@class,datos,'OutputFormat','cell');  
  
tabla_tipos = table(variables', tipos', 'VariableNames', {'NombreVariable', 'Tipo'})
```

```
tabla_tipos = 13x2 table
```

	NombreVariable	Tipo
1	'gender'	'double'
2	'situation'	'double'
3	'tea'	'double'
4	'coffee'	'double'
5	'height'	'double'
6	'weight'	'double'
7	'age'	'double'
8	'meat'	'double'
9	'fish'	'double'
10	'raw_fruit'	'double'
11	'cooked_fruit_veg'	'double'
12	'chocol'	'double'
13	'fat'	'double'

`varfun(@class,datos,'OutputFormat','cell')` aplica la función `class` a cada variable en la tabla `datos` y devuelve los tipos de datos en una celda

Observe que la tabla de los tipos de característica de este dataset son todo datos tipo **double**, este tipo de datos hace referencia a los **double precision** que son números de alta precisión; números flotantes, también conocidos como **floats** o decimales

Lo anterior tiene coherencia pues las respuestas de todos los participantes del estudio se almacenaron como números que van del 0 al 5, cantidad (kg, numero de tazas, cm, años) u opciones binarias entre 1 y 2.

Parte 2 - Análisis descriptivo

1. Realizar las tablas de frecuencia de los datos a los que aplica y elija como presentar los gráficos más apropiados según el tipo de variable.

2. Resumir la información presente mediante tablas, gráficos adecuados y las medidas de ubicación, dispersión y simetría para aquellas variables que aplique. Recuerde usar gráficos de Histogramas, diagramas de cajas y bigotes, gráficos de dispersión.

Se pueden responder las dos preguntas anteriores con lo siguiente:


```
for i = 1:length(variables)
    if ismember(variables{i}, {'height', 'weight', 'age', 'tea', 'coffee'})
        % Para variables continuas, muestra estadísticas descriptivas, un histograma y un diagrama de cajas y bigotes
        disp(['**Tabla de medidas de ubicación, dispersión y forma de la variable ', variables{i}, '**']);
        disp(['Valor mínimo de ', variables{i}, ': ', num2str(min(datos.(variables{i})))]);
        disp(['Valor máximo de ', variables{i}, ': ', num2str(max(datos.(variables{i})))]);
        disp(['Media de ', variables{i}, ': ', num2str(mean(datos.(variables{i})))]);
        disp(['Mediana de ', variables{i}, ': ', num2str(median(datos.(variables{i})))]);
        disp(['Desviación estándar de ', variables{i}, ': ', num2str(std(datos.(variables{i})))]);
        disp(['Curtosis de ', variables{i}, ': ', num2str(kurtosis(datos.(variables{i})))]);
        disp(['Asimetría de ', variables{i}, ': ', num2str(skewness(datos.(variables{i})))]);
        figure; % Crea una nueva figura
        histogram(datos.(variables{i}));
        title(['Histograma de ', variables{i}]); % Agrega un título al gráfico
        xlabel(variables{i}); % Etiqueta el eje x
        ylabel('Frecuencia'); % Etiqueta el eje y
        figure; % Crea una nueva figura
        boxplot(datos.(variables{i}));
        title(['Diagrama de cajas y bigotes de ', variables{i}]); % Agrega un título al gráfico
        xlabel(variables{i}); % Etiqueta el eje x
        ylabel('Valores'); % Etiqueta el eje y
    else
        % Para variables categóricas, muestra una tabla de frecuencias y un gráfico de barras
        tab = tabulate(datos.(variables{i}));
        disp(['**Tabla de frecuencias para la variable ', variables{i}, '**']);
        disp('Valores que toma la variable ');
        disp(tab(:,1));
        disp('Frecuencia ');
        disp(tab(:,2));
        disp('Frecuencia relativa (%) ');
        disp(tab(:,3));
        figure; % Crea una nueva figura
        bar(tab(:,2));
        title(['Gráfico de barras de ', variables{i}]); % Agrega un título al gráfico
        xlabel('Categorías'); % Etiqueta el eje x
        ylabel('Frecuencia'); % Etiqueta el eje y
        set(gca, 'XTickLabel', tab(:,1)); % Asigna las etiquetas de las categorías al eje x
    end
end
```

Tabla de frecuencias para la variable gender:

Valores que toma la variable

1
2

Frecuencia
85
141
Frecuencia relativa (%)
37.6106
62.3894



****Tabla de frecuencias para la variable situation:****

Valores que toma la variable

1
2
3

Frecuencia

98

119


9

Frecuencia relativa (%)

43.3628

52.6549

3.9823



****Tabla de medidas de ubicación, dispersión y forma de la variable tea:****

Valor mínimo de tea: 0

Valor máximo de tea: 10

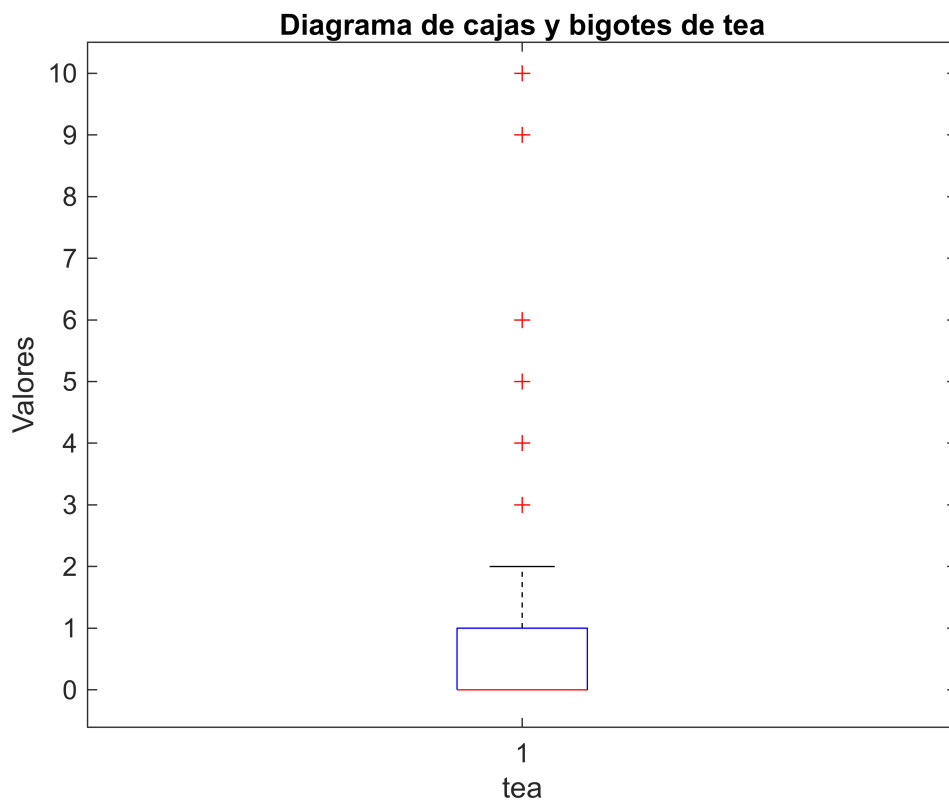

Media de tea: 0.71239

Mediana de tea: 0

Desviación estándar de tea: 1.4488


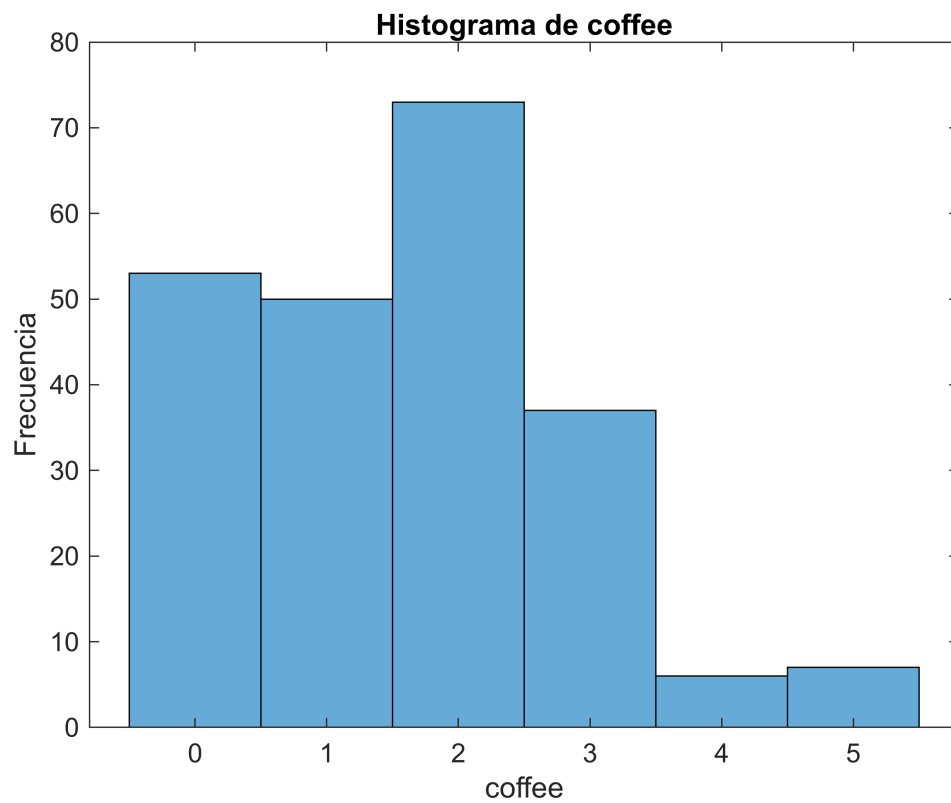
Curtosis de tea: 14.8628

Asimetría de tea: 2.9525



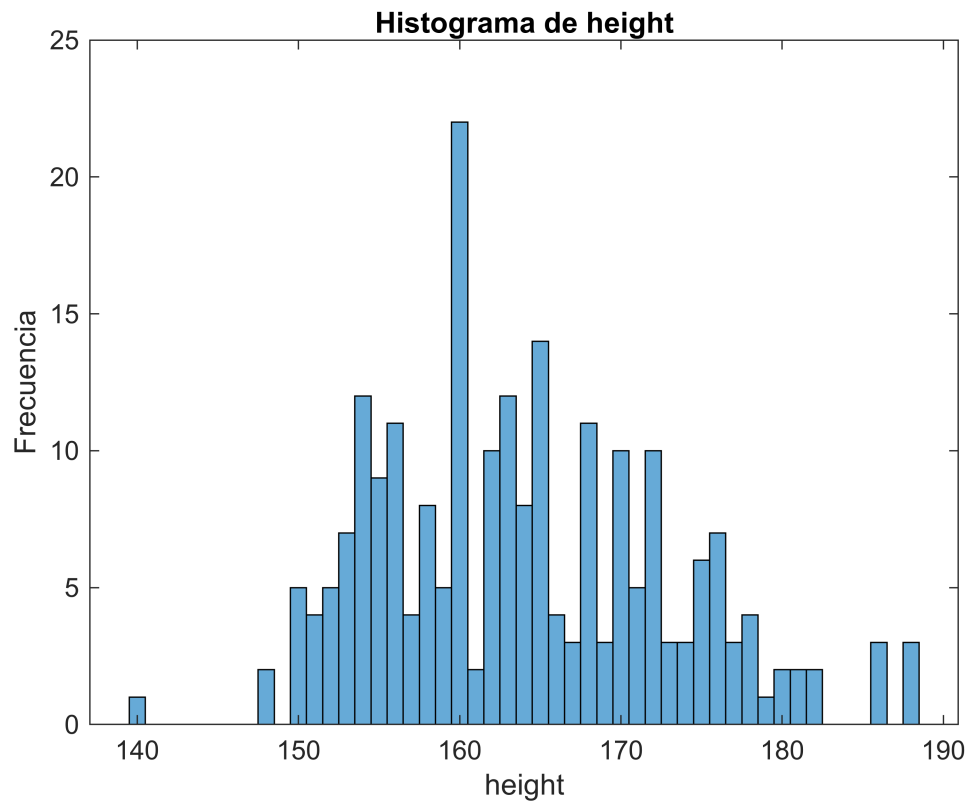
****Tabla de medidas de ubicación, dispersión y forma de la variable coffee:****
 Valor mínimo de coffee: 0
 Valor máximo de coffee: 5
 Media de coffee: 1.6195
 Mediana de coffee: 2


Desviación estándar de coffee: 1.253
Curtosis de coffee: 2.924
Asimetría de coffee: 0.48847



****Tabla de medidas de ubicación, dispersión y forma de la variable height:****
Valor mínimo de height: 140

Valor máximo de height: 188
Media de height: 163.9602
Mediana de height: 163
Desviación estándar de height: 9.0034
Curtosis de height: 2.7782
Asimetría de height: 0.42562





****Tabla de medidas de ubicación, dispersión y forma de la variable weight:****

Valor mínimo de weight: 38

Valor máximo de weight: 96



Media de weight: 66.4823

Mediana de weight: 66

Desviación estándar de weight: 12.0334

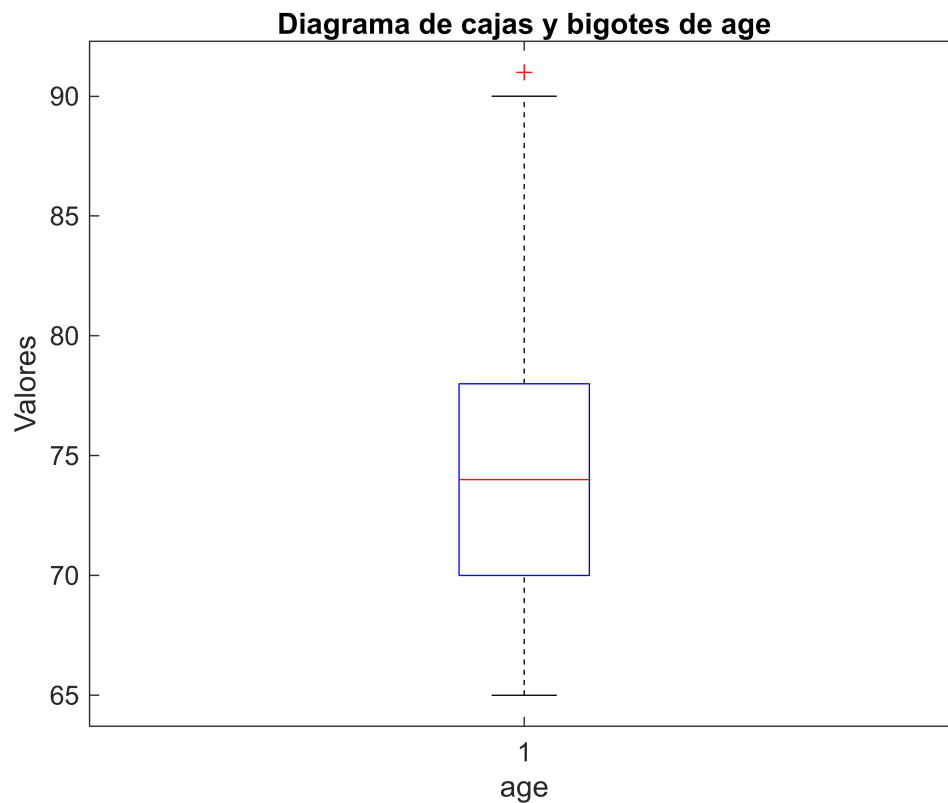
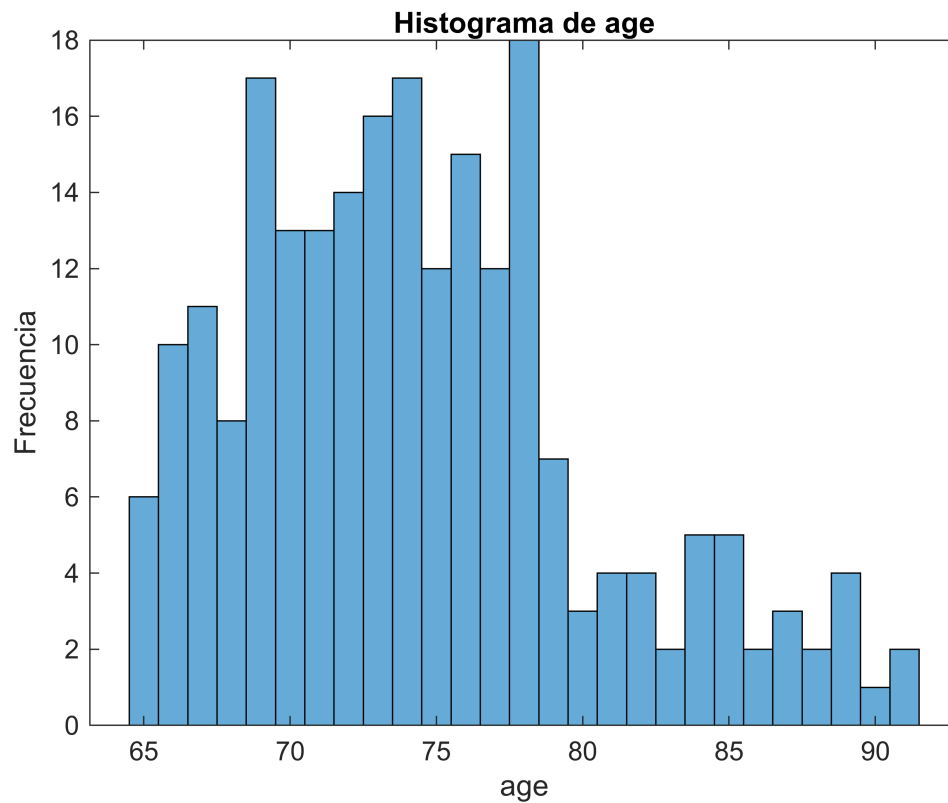
Curtosis de weight: 2.5062

Asimetría de weight: 0.14639



****Tabla de medidas de ubicación, dispersión y forma de la variable age:****
 Valor mínimo de age: 65
 Valor máximo de age: 91
 Media de age: 74.4779
 Mediana de age: 74

Desviación estándar de age: 6.0053
 Curtosis de age: 3.0017
 Asimetría de age: 0.66909

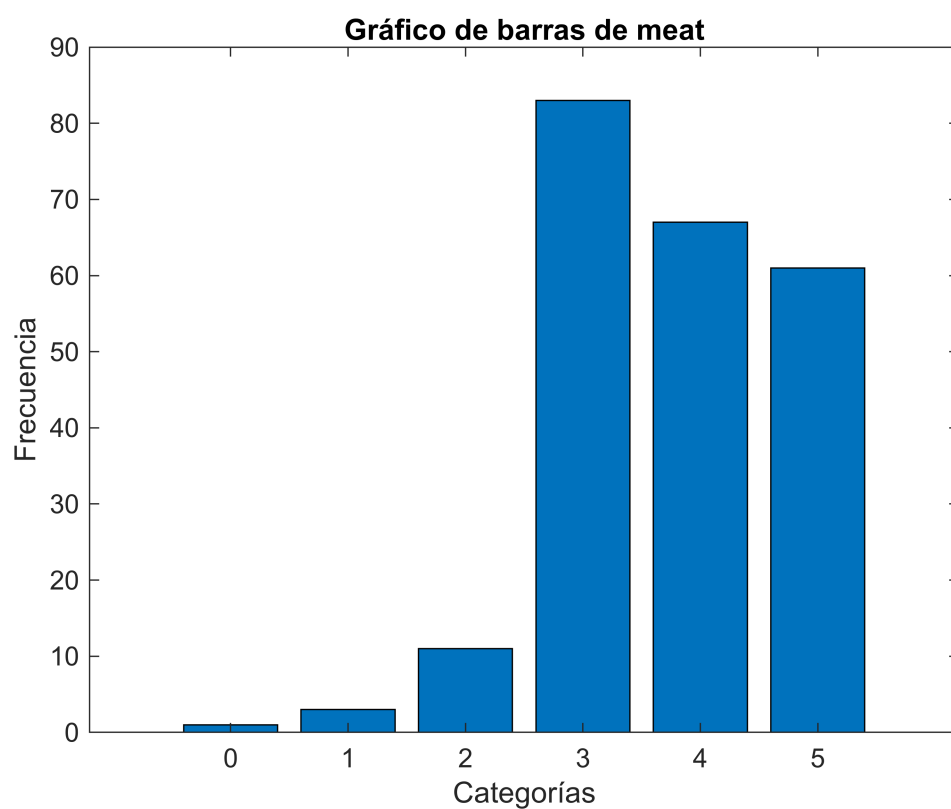


****Tabla de frecuencias para la variable meat:****
 Valores que toma la variable

```

0
1
2
3
4
5
Frecuencia
1
3
11
83
67
61
Frecuencia relativa (%)
0.4425
1.3274
4.8673
36.7257
29.6460
26.9912

```

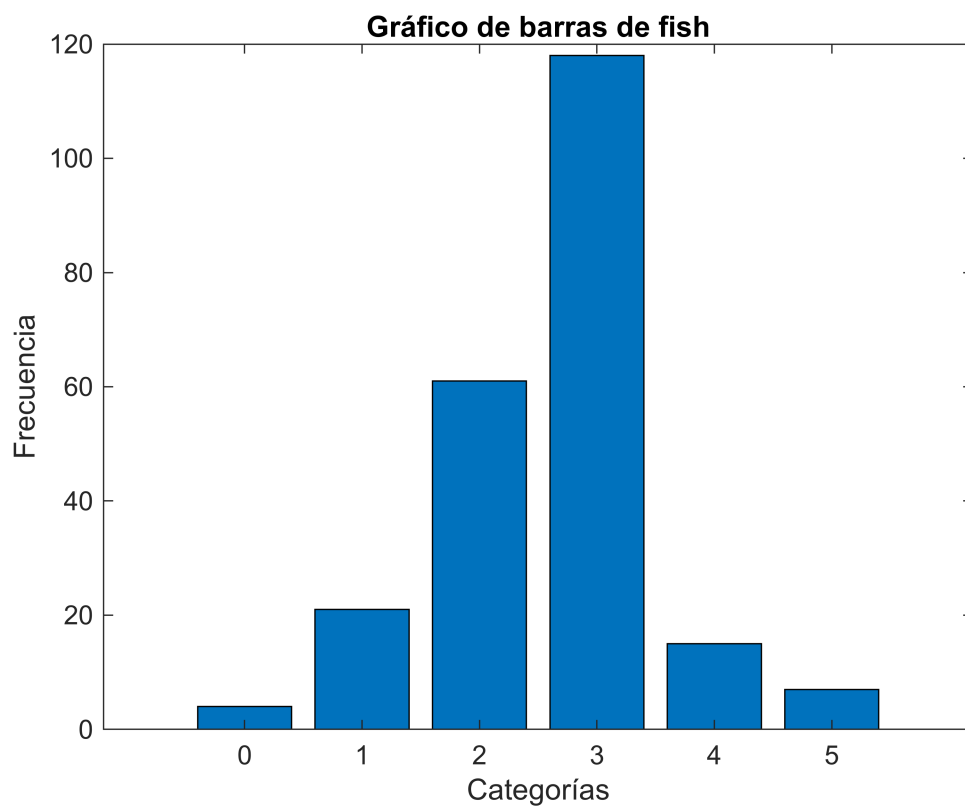


```

**Tabla de frecuencias para la variable fish:**
Valores que toma la variable
0
1
2
3
4
5
Frecuencia
4
21
61
118

```

15
7
Frecuencia relativa (%)
1.7699
9.2920
26.9912
52.2124
6.6372
3.0973



****Tabla de frecuencias para la variable raw_fruit:****

Valores que toma la variable

0

1

2

3

4

5

Frecuencia

2

8

8

14

22

172

Frecuencia relativa (%)

0.8850


3.5398

3.5398

6.1947

9.7345

76.1062



****Tabla de frecuencias para la variable cooked_fruit_veg:****

Valores que toma la variable

0

1

2

3

4

5

Frecuencia

2

3

7

30

36

148

Frecuencia relativa (%)

0.8850


1.3274

3.0973

13.2743

15.9292

65.4867



****Tabla de frecuencias para la variable chocol:****

Valores que toma la variable

0

1

2

3

4

5

Frecuencia

50

62

16

22

11

65

Frecuencia relativa (%)

22.1239


27.4336

7.0796

9.7345

4.8673

28.7611



****Tabla de frecuencias para la variable fat:****

Valores que toma la variable

1

2

3

4

5

6

7

8

Frecuencia

15

27

48

68

40

23

1

4

Frecuencia relativa (%)

6.6372

11.9469

21.2389

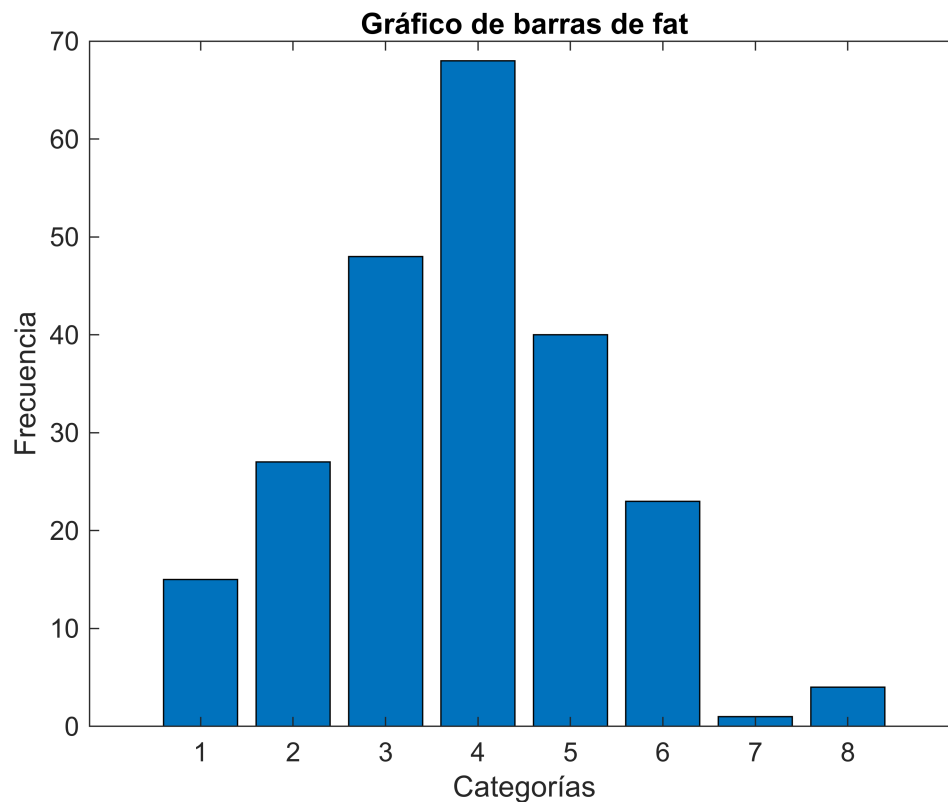
30.0885

17.6991

10.1770

0.4425

1.7699



En el código, se utilizan dos tipos de gráficos: **histogramas y gráficos de barras**. La elección entre estos dos depende del tipo de variable que se está analizando.

- **Histograma:** Se utiliza para variables continuas, como *'height'*, *'weight'*, *'age'*, *'tea'*, *'coffee'*. Las variables continuas pueden tomar cualquier valor dentro de un rango específico. Los histogramas son útiles para visualizar la distribución de los datos y pueden ayudar a identificar tendencias, valores atípicos y la forma de la distribución (por ejemplo, si es simétrica, sesgada a la derecha o a la izquierda).
- **Gráfico de barras:** Se utiliza para variables categóricas, que son aquellas que tienen un número limitado y fijo de categorías posibles. En este caso, todas las variables que no son *'height'*, *'weight'*, *'age'*, *'tea'*, *'coffee'* se consideran categóricas. Los gráficos de barras son útiles para comparar la frecuencia o proporción de cada categoría en la variable.

Las variables continuas pueden tomar cualquier valor dentro de un rango específico y, por lo tanto, tienen una distribución de datos que puede ser descrita por medidas de ubicación central (como la media o la mediana), medidas de dispersión (como la desviación estándar), y medidas de forma (como la curtosis y la asimetría).

- **Desviación estándar:** Mide cuánto se dispersan los datos alrededor de la media. Una desviación estándar alta indica que los datos están muy dispersos, mientras que una desviación estándar baja indica que los datos están muy concentrados alrededor de la media.

- **Curtosis:** Mide el “pico” o la “cola pesada” de la distribución. Una curtosis alta indica una distribución con colas pesadas y un pico agudo, mientras que una curtosis baja indica una distribución con colas ligeras y un pico menos pronunciado.
- **Asimetría:** Mide la simetría de la distribución. Una asimetría positiva indica una distribución con una cola derecha más larga, mientras que una asimetría negativa indica una distribución con una cola izquierda más larga.

El **diagrama de cajas y bigotes** es otra herramienta útil para visualizar la distribución de una variable continua. Muestra la mediana, los cuartiles y los valores atípicos, proporcionando una visión rápida de la distribución de los datos.

Por otro lado, las variables categóricas tienen un número limitado y fijo de categorías posibles. No tiene sentido calcular la desviación estándar, la curtosis o la asimetría para estas variables, ya que no tienen una distribución de datos en el sentido tradicional. En su lugar, se utilizan tablas de frecuencias y gráficos de barras para describir la distribución de una variable categórica. Estos muestran la frecuencia de cada categoría, lo que permite ver rápidamente qué categorías son las más comunes.

3. Observar a detalle las estadísticas e identificar si existen diferencias altas entre cada percentil y en los percentiles extremos con valores máximos y mínimos de cada característica/variable.

Para responder lo anterior se calcularán los percentiles de los datos y se compararán con los valores mínimos y máximos.

```
for i = 1:length(variables)
    if ismember(variables{i}, {'height', 'weight', 'age', 'tea', 'coffee'})
        % Para variables continuas, calcula los percentiles y compara con los valores mínimos y
        disp(['**Análisis de percentiles para la variable ', variables{i}, '**'])
        percentiles = prctile(datos.(variables{i}), [0 25 50 75 100]);
        disp(['Percentil 0 (mínimo) de ', variables{i}, ': ', num2str(percentiles(1))]);
        disp(['Percentil 25 de ', variables{i}, ': ', num2str(percentiles(2))]);
        disp(['Percentil 50 (mediana) de ', variables{i}, ': ', num2str(percentiles(3))]);
        disp(['Percentil 75 de ', variables{i}, ': ', num2str(percentiles(4))]);
        disp(['Percentil 100 (máximo) de ', variables{i}, ': ', num2str(percentiles(5))]);
        disp(['Diferencia entre percentil 25 y mínimo de ', variables{i}, ': ', num2str(percentiles(2)-percentiles(1))]);
        disp(['Diferencia entre percentil 75 y máximo de ', variables{i}, ': ', num2str(percentiles(4)-percentiles(5))]);
        disp(' ')
    end
end
```

```
**Análisis de percentiles para la variable tea:**
Percentil 0 (mínimo) de tea: 0
Percentil 25 de tea: 0
Percentil 50 (mediana) de tea: 0
Percentil 75 de tea: 1
Percentil 100 (máximo) de tea: 10
Diferencia entre percentil 25 y mínimo de tea: 0
Diferencia entre percentil 75 y máximo de tea: 9

**Análisis de percentiles para la variable coffee:**
Percentil 0 (mínimo) de coffee: 0
Percentil 25 de coffee: 1
```

Percentil 50 (mediana) de coffee: 2
Percentil 75 de coffee: 2
Percentil 100 (máximo) de coffee: 5
Diferencia entre percentil 25 y mínimo de coffee: 1
Diferencia entre percentil 75 y máximo de coffee: 3

****Análisis de percentiles para la variable height:****
Percentil 0 (mínimo) de height: 140
Percentil 25 de height: 157
Percentil 50 (mediana) de height: 163
Percentil 75 de height: 170
Percentil 100 (máximo) de height: 188
Diferencia entre percentil 25 y mínimo de height: 17
Diferencia entre percentil 75 y máximo de height: 18

****Análisis de percentiles para la variable weight:****
Percentil 0 (mínimo) de weight: 38
Percentil 25 de weight: 57
Percentil 50 (mediana) de weight: 66
Percentil 75 de weight: 75
Percentil 100 (máximo) de weight: 96
Diferencia entre percentil 25 y mínimo de weight: 19
Diferencia entre percentil 75 y máximo de weight: 21

****Análisis de percentiles para la variable age:****
Percentil 0 (mínimo) de age: 65
Percentil 25 de age: 70
Percentil 50 (mediana) de age: 74
Percentil 75 de age: 78
Percentil 100 (máximo) de age: 91
Diferencia entre percentil 25 y mínimo de age: 5
Diferencia entre percentil 75 y máximo de age: 13

La diferencia entre el percentil 25 y el mínimo, y entre el percentil 75 y el máximo ayudan a identificar si existen diferencias altas entre cada percentil y en los percentiles extremos con los valores máximos y mínimos. Si estas diferencias son grandes, podría indicar la presencia de valores atípicos en los datos.

A partir del análisis de percentiles, se concluye:

- **Té (tea):** La mayoría de las personas mayores no consumen té a diario (mediana y percentil 25 son 0). Sin embargo, hay una diferencia significativa entre el percentil 75 y el valor máximo (9 tazas), lo que indica que hay algunas personas que consumen una cantidad considerable de té al día.
- **Café (coffee):** A diferencia del té, la mayoría de las personas mayores consumen al menos una taza de café al día (percentil 25 es 1 y mediana es 2). La diferencia entre el percentil 75 y el valor máximo es de 3 tazas, lo que indica una menor variabilidad en el consumo de café en comparación con el té.
- **Altura (height):** La altura de las personas mayores varía entre 140 cm y 188 cm, con una mediana de 163 cm. La diferencia entre el percentil 25 y el mínimo, así como entre el percentil 75 y el máximo, es relativamente pequeña (17 cm y 18 cm respectivamente), lo que indica que la mayoría de las personas mayores tienen una altura dentro de este rango.
- **Peso (weight):** El peso de las personas mayores varía entre 38 kg y 96 kg, con una mediana de 66 kg. La diferencia entre el percentil 25 y el mínimo, así como entre el percentil 75 y el máximo, es relativamente pequeña (19 kg y 21 kg respectivamente), lo que indica que la mayoría de las personas mayores tienen un peso dentro de este rango. En otras palabras, el 50% central de los datos que se

encuentra entre el percentil 25 y el percentil 75 están concentrados alrededor de la mediana (66 kg), con una variabilidad de alrededor de 18 kg (75 kg - 57 kg).

- **Edad (age):** La edad de las personas mayores varía entre 65 años y 91 años, con una mediana de 74 años. La diferencia entre el percentil 25 y el mínimo es de 5 años, mientras que la diferencia entre el percentil 75 y el máximo es de 13 años. Esto indica que hay una mayor variabilidad en la edad de las personas mayores en el extremo superior del rango de edades.

4. Identificar si existen valores atípicos en las variables, ¿estos valores podrían generar un falso análisis?

Para identificar los valores atípicos se utilizará el método del rango intercuartil (IQR). Este método considera como valores atípicos aquellos que están por debajo del primer cuartil menos 1.5 veces el IQR o por encima del tercer cuartil más 1.5 veces el IQR.

```
for i = 1:length(variables)
    if ismember(variables{i}, {'height', 'weight', 'age', 'tea', 'coffee'})
        % Para variables continuas, calcula los percentiles y identifica los valores atípicos
        disp(' ');
        disp('=====');
        disp(' ');
        disp(['**Análisis de valores atípicos para la variable ', variables{i}, '**'])
        Q1 = prctile(datos.(variables{i}), 25);
        Q3 = prctile(datos.(variables{i}), 75);
        IQR = Q3 - Q1;
        lower_bound = Q1 - 1.5 * IQR;
        upper_bound = Q3 + 1.5 * IQR;
        outliers = datos.(variables{i}) < lower_bound | datos.(variables{i}) > upper_bound;
        disp(['Número de valores atípicos en ', variables{i}, ': ', num2str(sum(outliers))]);
    end
end
```

```
=====

**Análisis de valores atípicos para la variable tea**
Número de valores atípicos en tea: 21

=====

**Análisis de valores atípicos para la variable coffee**
Número de valores atípicos en coffee: 13

=====

**Análisis de valores atípicos para la variable height**
Número de valores atípicos en height: 0

=====

**Análisis de valores atípicos para la variable weight**
Número de valores atípicos en weight: 0

=====
```

****Análisis de valores atípicos para la variable age****
Número de valores atípicos en age: 2

Los valores atípicos pueden tener un impacto significativo en las estadísticas descriptivas, como la media y la desviación estándar, y pueden sesgar los resultados.

Por ejemplo, un valor atípico muy alto puede aumentar la media, dando la impresión de que todos los valores son más altos de lo que realmente son. Del mismo modo, los valores atípicos pueden aumentar la desviación estándar, dando la impresión de que los datos son más dispersos de lo que realmente son.

Por lo tanto, es importante identificar y tratar adecuadamente los valores atípicos antes de realizar un análisis de los datos. Esto podría implicar eliminar los valores atípicos, transformar los datos, o utilizar otros tipos de métodos estadísticos más complejos que tengan en cuenta la naturaleza de dichos valores atípicos

Parte 3 - Análisis entre variables

1. Elegir qué variables (mínimo 2) permiten agrupar todos los datos para realizar análisis comparativo por grupos, luego analice las variables según su elección. Elabore gráficos adecuados para presentar la información.